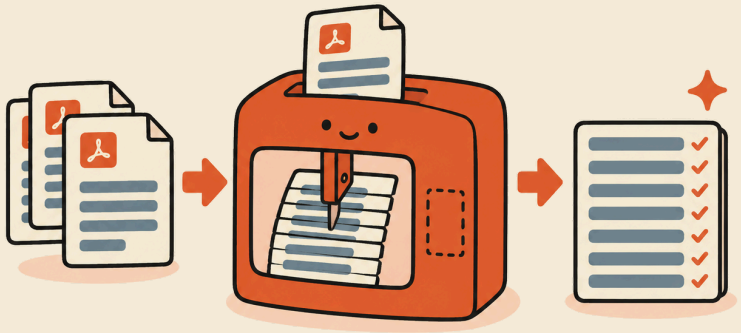
TAREFA 7 · FUNCIONAMENTO

A ferramenta funcionando

Como um PDF vira dados, e como vamos medir isso



Beatriz Machado · Cristhian Kapelinski · Guilherme Klauberg

UNIPAMPA · Inteligência Artificial Aplicada

ONDE ESTAMOS

As três primeiras etapas ficaram prontas

01 · FEITA
Dados

02 · FEITA
Piso por regras

03 · FEITA
Pipeline

04 · PRÓXIMA
Teto

05
Seleção

06
Ajuste fino

07
Experimentos

08
Fechamento

Hoje: como funciona e como se mede. Os números vêm na próxima tarefa.

AS PEÇAS

Com o que foi feito

Python 3.11
Pacote de linha de comando

pypdfium2
Lê o texto do PDF, sem OCR

Config JSON
Uma por scanner: onde cada achado começa

Prompt
Um por scanner: regras campo a campo

Pydantic
Resposta só vale se for o JSON esperado

Cliente OpenAI
Nuvem ou local, a mesma chamada

Scanner novo: um JSON e um prompt, sem mudar código.

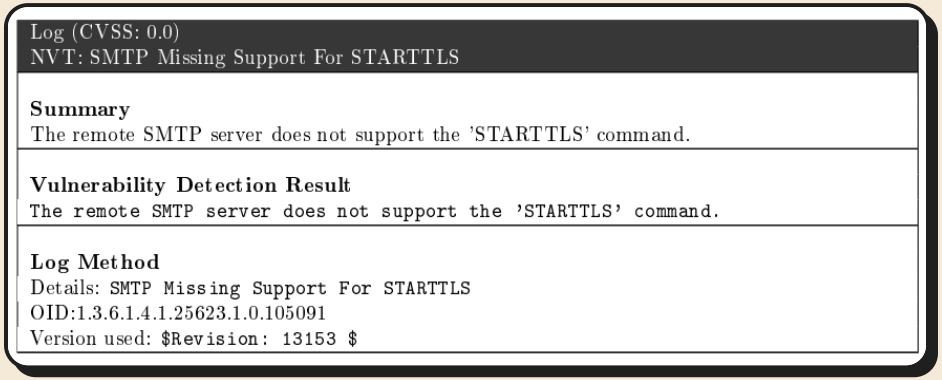
O relatório entra como está

PDF → Texto → Blocos → Lotes → LLM → Dados

O PDF do OpenVAS, sem conversão.

Ao lado, um achado real que vamos seguir até o fim.

Juice Shop · 24 páginas · 34 achados



Log (CVSS: 0.0)
NVT: SMTP Missing Support For STARTTLS

Summary
The remote SMTP server does not support the 'STARTTLS' command.

Vulnerability Detection Result
`The remote SMTP server does not support the 'STARTTLS' command.`

Log Method
Details: `SMTP Missing Support For STARTTLS`
OID:1.3.6.1.4.1.25623.1.0.105091
Version used: `$Revision: 13153 $`

Texto extraído e limpo

PDF → **Texto** → Blocos → Lotes → LLM → Dados

O texto sai do PDF com defeitos.

Cabeçalho de página e quebras saem antes do modelo.

```
2 RESULTS PER HOST 16
Log (CVSS: 0.0)
NVT: SMTP Missing Support
For STARTTLS
. . . continues on next page . . .
Summary
The remote SMTP server does
not support the 'STARTTLS'
command.
```

Um bloco por achado

PDF → Texto → **Blocos** → Lotes → LLM → Dados

Uma expressão regular acha a linha que abre cada achado.

Host e porta vêm do cabeçalho da página.

34 blocos no PDF, 34 linhas na planilha do scanner

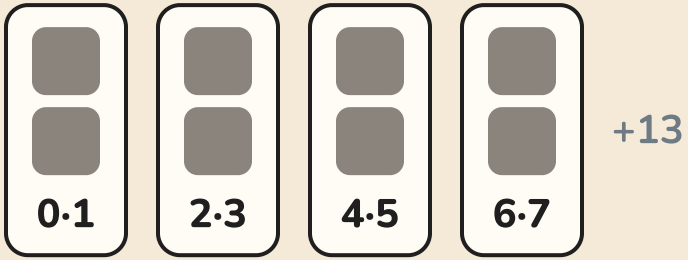
```
### BLOCK 21 (host: 127.0.0.1,
              port: 25/tcp)
Log (CVSS: 0.0)
NVT: SMTP Missing Support
For STARTTLS
Summary
The remote SMTP server does
not support the 'STARTTLS'
command.
```

Blocos inteiros, agrupados em lotes

PDF → Texto → Blocos → **Lotes** → LLM → Dados

Nenhum bloco é cortado. No OpenVAS, 2 por chamada.

Lote recusado volta em lote de 1, até 3 tentativas.



34 blocos

17 lotes de 2

17 chamadas

O modelo preenche, não descobre

PDF → Texto → Blocos → Lotes → **LLM** → Dados

Única etapa com modelo.

O bloco 21 volta como bloco 21, ou a resposta é recusada.

```
{
  "block_id": 21,
  "Name": "SMTP Missing Support
           For STARTTLS",
  "severity": "LOG", "cvss": 0.0,
  "port": 25, "protocol": "tcp",
  "description": ["The remote SMTP
     server does not support..."]
}
```

COMO FUNCIONA · ETAPA 6 DE 6

Um registro por achado

PDF → Texto → Blocos → Lotes → LLM → **Dados**

Em rosa: garantido por regra.

O resto é o que o modelo preencheu, e o que a prova vai medir.

`name`	SMTP Missing Support For STARTTLS
`severity`	LOG
`description`	The remote SMTP server does not support the 'STARTTLS' command.
`host`	**127.0.0.1**
`port`	**25 / tcp**
`source`	**OPENVAS**

COMO SE MEDE

As quatro perguntas da prova

Encontrou?
Achados que viraram registro, e os inventados

Acerto exato
Severidade, porta, id: igual ou errado

O texto bate?
Descrição e solução, de 0 a 1

Quanto custa
Tempo, API e se o relatório sai

Gabarito: a planilha que o scanner exporta junto com o PDF.

USO

Linha de comando e saídas

```
# nuvem
$ mulitaminer extract relatorio.pdf --scanner openvas
      --model deepseek

# local, sem chave de API
$ mulitaminer extract relatorio.pdf --scanner openvas
      --model mulita-qwen2.5-1.5b
```

JSON XLSX CSV SARIF CSAF DefectDojo

Trocar de modelo é trocar um argumento.

PRÓXIMOS PASSOS

Agora os modelos entram

HOJE

Pipeline pronto

Falta a nota

PRÓXIMA

Modelo de nuvem

Os primeiros números

DEPOIS

Local e ajustado

Dentro da organização

